

Probabilidade de Incêndio no Território do Brasil

Duarte, T. S.

Abstract—A análise de séries temporais de imagens permite a identificação de tendências, padrões sazonais e eventos anômalos, como incêndios florestais, que podem causar impactos significativos no meio ambiente. Por exemplo, a detecção precoce de incêndios usando imagens de satélite pode salvar ecossistemas e vidas, demonstrando a relevância deste campo de estudo no contexto atual de mudanças climáticas e desafios ambientais. O objetivo desse trabalho é propor um modelo de aprendizagem profunda para prever a probabilidade de incêndios florestais no território do Brasil, utilizando dados de sensoriamento remoto. O modelo é composto por uma Rede Neural Convolutacional (CNN), uma Rede Neural Recorrente de Memória de Curto Prazo (LSTM) e uma Rede Neural Totalmente Conectada (FCN), e é treinado com dados de focos de incêndio, precipitação, temperatura, umidade relativa do ar e número de dias sem chuva.

I. INTRODUÇÃO

O sensoriamento remoto é uma tecnologia crucial para monitorar e entender as dinâmicas ambientais da Terra. Com a difusão do acesso a poderes computacionais cada vez maiores para uso doméstico e acadêmico, métodos de aprendizagem estatística têm sido aplicado com sucesso no sensoriamento remoto. Devido à natureza dos dados desse paradigma – sinais eletromagnéticos captados em sensores de satélites, geralmente convertidos para arquivos de estrutura matricial ou tensorial – é comum a associação de métodos orientados a imagens. Eventualmente é possível contornar os problemas de custo computacional inerentes a esse tipo de método através de estratégias baseadas em taxonomias, onde as imagens passam por algoritmos de extração de características, que populam datasets tabulares e que, portanto, podem ser usados em algoritmos clássicos de aprendizagem de máquina ao serem tratados como problemas de classificação, por exemplo [1], [2].

Ambas as abordagens citadas têm em comum o fato de, implicitamente, considerarem o problema como invariante por transformações temporais. Uma abordagem alternativa à uma redução de dimensionalidade ou uma transformação de características de imagens baseadas em taxonomias, para posterior análise de séries temporais, é a aprendizagem da representação das correlações entre eventos e features ao longo do tempo. Essa abordagem é especialmente interessante para o sensoriamento remoto, uma vez que a maioria dos dados de satélite são naturalmente organizados em séries temporais tensoriais. No contexto de aprendizagem profunda, esse tipo de problema pode ser tratado com o uso de redes neurais recorrentes, que são capazes de aprender representações de sequências de dados, e que podem ser combinadas com redes neurais convolucionais para extrair características espaciais de dados de sensoriamento remoto. Nesse trabalho é proposto um modelo de aprendizagem profunda para prever a probabilidade de incêndios florestais

no território do Brasil, utilizando dados de sensoriamento remoto. O modelo é composto por uma Rede Neural Convolutacional, uma Rede Neural Recorrente de Memória de Curto Prazo, e uma Rede Neural Totalmente Conectada.

II. MÉTODOS

A. Hardware e Software

O modelo foi desenvolvido em um sistema operacional *Ubuntu Linux 22.04* de 64 bits, equipado com 16 GB de RAM e um processador *AMD Ryzen 7 3700X* de 8 núcleos. A unidade de processamento gráfico utilizada foi uma *NVIDIA GeForce GTX 1660 Ti*. Todos os códigos foram implementados e executados utilizando a linguagem de programação *Python*, na versão 3.10.12. Especificamente, o modelo de predição de incêndios florestais foi desenvolvido com o uso da biblioteca *PyTorch*, versão 2.0.0+cu117. O código fonte está disponível no repositório GitHub *ppgcc-deep-learning-pinn* [3].

B. Dados

Os dados utilizados no modelo foram obtidos através do site do *Projeto Queimadas* do Instituto Nacional de Pesquisas Espaciais (INPE) [4], o qual fornece medidas de sensoriamento remoto de incêndios florestais no Brasil desde 1998. Estes incluem informações diárias sobre focos de incêndio, capturadas por uma rede de dez satélites polares e óticos operando na faixa termal-média de 4 μm . Este conjunto gera aproximadamente 200 imagens diariamente com periodicidades horárias e diárias, que são posteriormente reprocessadas e sumarizadas mensalmente.

Após uma análise exploratória inicial, foram selecionados os seguintes conjuntos de dados para o modelo:

- **Focos de Incêndio:** variável resposta composta por dados diários de focos de incêndio, em formato CSV 2 [5].
- **Precipitação:** variável explicativa com dados diários de precipitação, em formato netCDF, com unidades de medida não explicitadas e dimensões de 901x850 em latitude e longitude 4 [6].
- **Temperatura:** variável explicativa com dados diários de temperatura, em formato netCDF, com unidades de medida não explicitadas e dimensões de 361x345 em latitude e longitude 6 [7].
- **Umidade Relativa do Ar:** variável explicativa com dados diários de umidade relativa do ar, em formato netCDF, com unidades de medida não explicitadas e dimensões de 361x345 em latitude e longitude 5 [8].
- **Número de Dias Sem Chuva:** variável explicativa com o número de dias sem chuva em um período de 120

dias, em formato netCDF, com dimensões de 850x901 em latitude e longitude 3 [9].

O período considerado para a análise temporal diária foi de 19 de outubro de 2023 a 24 de novembro de 2023 1.

INPE's Wildfire Data Availability Over Time




Fig. 1: Disponibilidade temporal dos dados.

C. Preparação dos Dados

As matrizes foram padronizadas e utilizadas como camadas de tensores de entrada do modelo, com cada matriz resultante de um gráfico geográfico com projeção cilíndrica de Plate Carrée e dimensões de 300x300. O tensor final para cada um dos N dias de observação possui a dimensionalidade: $(N, 5, 300, 300)$. O pseudocódigo a seguir ilustra o processo de preparação dos dados para o modelo:

Algorithm 1 Preparação dos Dados

```

1: procedure PREPARACAO_DADOS(dados, nome_coluna)
2:    $MAX\_LAT \leftarrow 32.99499999641088$ 
3:    $MIN\_LAT \leftarrow -55.985000000358912$ 
4:    $MAX\_LON \leftarrow -33.009801806103724$ 
5:    $MIN\_LON \leftarrow -119.98980180610373$ 
6:   Cria figura com projeção PlateCarree
7:   Define as coordenadas com base nas constantes de
   latitude e longitude
8:   Exibe a figura
9:    $dados \leftarrow$  extrai RGB da figura
10:   $soma\_canais \leftarrow$  soma dos canais de  $dados$ 
11:  return  $soma\_canais$ 
12: end procedure

```

A construção da variável resposta foi realizada de maneira análoga, porém com a criação de histogramas bidimensionais em vez de imagens geográficas, aplicando-se uma condição de binarização para simplificar a modelagem do problema.

Os dados foram submetidos a um processo de normalização, garantindo que tanto os valores de entrada quanto os de saída variem entre 0 e 1. Dada a natureza tensorial do conjunto de

Wildfire




Fig. 2: Focos de incêndio.

Days Without Rain



Fig. 3: Dias sem chuva.

dados, optou-se por realizar a normalização ao longo do eixo 2, correspondente à profundidade. Este processo envolveu a padronização dos dados, onde a média e o desvio padrão de cada camada foram calculados e aplicados ao longo do eixo temporal, de acordo com a equação 1.

$$\hat{x}_{i,j,k,l,m} = \frac{x_{i,j,k,l,m} - \mu_k}{\sigma_k} \quad (1)$$

Para as etapas de treinamento e validação do modelo, o conjunto de dados foi dividido em proporções de 70% e 30%, respectivamente. Especificamente, das 37 amostras disponíveis, 25 foram alocadas para o treinamento e as 12 restantes para a validação do modelo.

D. Modelo

O modelo preditivo desenvolvido combina três arquiteturas de rede neural: uma Rede Neural Convolutacional (CNN), uma

Precipitation




Fig. 4: Precipitação.

Temperature



Fig. 6: Temperatura.

Relative Humidity




Fig. 5: Umidade relativa do ar.

Rede Neural Recorrente de Memória de Curto Prazo (LSTM) e uma Rede Neural Totalmente Conectada (FCN). A arquitetura resultante é caracterizada da seguinte forma: A primeira camada convolucional, com `input_channels` canais de entrada e `conv1_channels` canais de saída, emprega um kernel de tamanho 3, passo de 2 e preenchimento de 1, utilizando a função de ativação ReLU. A segunda camada convolucional, recebendo `conv1_channels` canais de entrada e reduzindo para `conv2_channels` canais de saída, mantém as mesmas configurações de kernel, passo e preenchimento, e também aplica a função ReLU. A camada LSTM processa a saída da segunda camada convolucional, convertida em um vetor unidimensional, e produz uma saída com `lstm_hidden_size` unidades ocultas. A rede totalmente conectada inclui uma camada oculta de `fc_hidden_size` e uma camada de saída de `output_size`, com a saída final sendo transformada em uma matriz de 300x300 e passada por uma função sigmoide para gerar a predição probabilística do modelo.

Os parâmetros do modelo incluem os tamanhos das camadas convolucionais, a dimensão da camada LSTM, o tamanho da camada oculta da FCN e as dimensões da camada de saída. Além disso, o tamanho do lote de amostras é um

Algorithm 2 CNN + LSTM + FCN

```

1: procedure WILDFIREPREDICTOR
2:   Primeira camada de convolução reduz dimensões pela
   metade e muda quantidade de canais
3:   Segunda camada de convolução reduz dimensões pela
   metade e muda quantidade de canais
4:   Camada LSTM processa saída de camada convolu-
   cional 1-dimensionalizada
5:   Camada linear completamente conectada processa
   saída de camada LSTM
6: end procedure
7: procedure FORWARD(X)
8:   for cada passo temporal de X do
9:     Aplicar primeira camada convolucional e função
     de ativação
10:    Aplicar segunda camada convolucional e função de
    ativação
11:    Armazenar resultado
12:   end for
13:   Aplicar camada LSTM nos resultados armazenados
14:   Aplicar camada linear no último output da camada
   LSTM
15:   Aplicar função de ativação sigmoide
16:   return resultado
17: end procedure

```

hiperparâmetro implícito, determinando a temporalidade considerada pela componente LSTM do modelo. O treinamento foi realizado com o otimizador Adam, taxa de aprendizado de 0.001, e a função de perda de entropia cruzada binária.

E. Treinamento e Validação

O treinamento do modelo foi conduzido ao longo de 30 épocas, utilizando um tamanho de lote (*batch*) contendo uma única amostra. Em cada época, o conjunto de dados foi aleatoriamente embaralhado e dividido, designando 25 amostras para o treinamento e 12 amostras para a validação.

Devido à natureza probabilística do problema, foi escolhida a métrica Brier Loss para avaliar o desempenho do modelo.

A Brier Loss é uma função de perda quadrática que mede a diferença entre a probabilidade prevista e a probabilidade real de um evento ocorrer [2].

$$\text{Brier Loss} = \frac{1}{N} \sum_{i=1}^N (y_i - p_i)^2 \quad (2)$$

Além disso os dados podem ser considerados desbalanceados em relação à variável resposta, uma vez que a maioria das amostras não apresenta focos de incêndio. Portanto, a métrica de acurácia balanceada também foi utilizada para avaliar o desempenho do modelo [3].

$$\text{Balanced Accuracy} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right) \quad (3)$$

Ambas as métricas foram calculadas element-wise e posteriormente agregadas para obter o resultado final. Em particular, para o cálculo da acurácia balanceada, em que é necessário um valor binário, foi definido o threshold de 0.5 para a probabilidade de incêndio.

F. Experimentos

Foram realizados experimentos para avaliar o impacto de diferentes parâmetros de arquitetura do modelo e de treinamento. Os resultados dos experimentos são apresentados na seção de resultados. Também foi realizado um experimento para avaliar o impacto da inclusão de estratégias típicas de problemas de aprendizado profundo em visão computacional, como max pooling e dropout, além de batch normalization, porém os resultados não apresentaram melhoria significativa com respeito à abordagem escolhida inicialmente e, portanto, não foram incluídos neste trabalho.

III. RESULTADOS

Os resultados dos experimentos são apresentados na tabela ???. O modelo com melhor desempenho foi o que utilizou 30 épocas de treinamento, com uma camada convolucional de 4 canais de entrada e 3 canais de saída, uma camada convolucional de 3 canais de entrada e 1 canal de saída, uma camada LSTM de 5625 unidades ocultas, e uma camada FCN de 32 unidades ocultas.

A figura 7 apresenta a função de perda ao longo das épocas de treinamento.

IV. CONCLUSÕES

A característica mais notável do modelo é a invariância das métricas de avaliação – bem como do valor assintótico da função perda – com respeito a alterações de hiperparâmetros. Em outras palavras, a estagnação dos valores desses valores, por um lado indica que o modelo não apresenta overfitting, mas por outro lado indica que o modelo não está aprendendo a relação entre as variáveis explicativas e a variável resposta. Esse problema pode ser contornado com o aumento do tamanho do conjunto de dados, o que não foi possível devido à limitação de dados disponíveis. Para contornar isso é




Fig. 7: Função de perda ao longo das épocas de treinamento.




Fig. 8: Variável resposta.

possível adaptar a preparação de dados para o uso de datasets alternativos de incêndios florestais, como o projeto FIRMS da NASA [10]–[12], que fornece dados globais de focos de incêndio.

Com respeito à aprendizagem, comparando uma amostra da variável resposta 8 no conjunto de validação, com as probabilidades 9 e previsões correspondentes 10, nota-se que o modelo consegue aprender a representação de elementos básicos da distribuição geoespacial dos incêndios, por exemplo que é improvável que haja focos de incêndios no mar ou, mais útil do ponto de vista prático, que as maiores probabilidades de incêndio estão concentradas nas regiões nordeste e centroeste do território.

REFERENCES

- [1] M. A. Dias, G. C. Marinho, R. G. Negri, W. Casaca, I. B. Muñoz, and D. M. Eler, "A machine learning strategy based on kittler's taxonomy to detect anomalies and recognize contexts applied to monitor water bodies in environments," *Remote Sensing*, vol. 14, no. 9, p. 2222, May 2022. [Online]. Available: <http://dx.doi.org/10.3390/rs14092222>
- [2] M. A. Dias, E. A. d. Silva, S. C. d. Azevedo, W. Casaca, T. Statella, and R. G. Negri, "An incongruence-based anomaly detection strategy for analyzing water pollution in images from remote sensing," *Remote Sensing*, vol. 12, no. 1, p. 43, Dec. 2019. [Online]. Available: <http://dx.doi.org/10.3390/rs12010043>

Epochs	Modelo	Brier Score	Balanced Accuracy
30	Conv1: 4→3, Conv2: 3→1, LSTM: 5625→32, FC: 32→90000	0.0347	0.6163
30	Conv1: 4→3, Conv2: 3→2, LSTM: 11250→64, FC: 64→90000	0.0347	0.6165
10	Conv1: 4→8, Conv2: 8→16, LSTM: 90000→64, FC: 64→90000	0.0660	0.6169
100	Conv1: 4→6, Conv2: 6→12, LSTM: 67500→64, FC: 64→90000	0.0347	0.6163

TABLE I: Resultados dos experimentos alterando os parâmetros de arquitetura do modelo e de treinamento. Conv: $x \rightarrow y$ representa a camada de convolução alterando a dimensão de profundidade do tensor de x para y ; LSTM: $x \rightarrow y$ representa a camada LSTM alterando o vetor output das camadas de convolução de x para y ; FC: $x \rightarrow y$ representa a camada FC alterando o vetor output da camada LSTM de x para y .



Fig. 9: Probabilidade de incêndio.



Fig. 10: Predição do modelo.

- [6] —, “Conjunto de dados de queimadas de terrasbrasilis, precipitação,” 2023. [Online]. Available: https://dataserver-coids.inpe.br/queimadas/queimadas/riscofogo_meteorologia/observado/precipitacao/?C=M;O=D
- [7] —, “Conjunto de dados de queimadas de terrasbrasilis, temperatura,” 2023. [Online]. Available: https://dataserver-coids.inpe.br/queimadas/queimadas/riscofogo_meteorologia/observado/temperatura/?C=M;O=D
- [8] —, “Conjunto de dados de queimadas de terrasbrasilis, humedade relativa,” 2023. [Online]. Available: https://dataserver-coids.inpe.br/queimadas/queimadas/riscofogo_meteorologia/observado/umidade_relativa/?C=M;O=D
- [9] —, “Conjunto de dados de queimadas de terrasbrasilis, número de dias sin lluvia,” 2023. [Online]. Available: https://dataserver-coids.inpe.br/queimadas/queimadas/riscofogo_meteorologia/observado/numero_dias_sem_chuva/?C=M;O=D
- [10] W. Schroeder and Land Atmosphere Near Real-Time Capability For EOS Fire Information For Resource Management System, “Viirs (noaa-20/jpss-1) i band 375 m active fire locations nrt (vector data),” 2020. [Online]. Available: <https://earthdata.nasa.gov/earth-observation-data/near-real-time/firms/vj114imgtdl-nrt>
- [11] —, “Viirs (s-npp) i band 375 m active fire locations nrt (vector data),” 2020. [Online]. Available: <https://earthdata.nasa.gov/earth-observation-data/near-real-time/firms/v1-vnp14imgt>
- [12] Land Atmosphere Near Real-Time Capability For EOS Fire Information For Resource Management System, “Modis/aqua+terra thermal anomalies/fire locations 1km firms v006 nrt (vector data),” 2021. [Online]. Available: <https://earthdata.nasa.gov/earth-observation-data/near-real-time/firms/mcd14dl>

- [3] thiagodsd, “Physics-informed neural network (pinn) for solving differential equations - graduate course project,” GitHub repository, 2023, applying neural networks to solve differential equations in a deep learning graduate course project. [Online]. Available: <https://github.com/thiagodsd/ppgcc-deep-learning-pinn/tree/wildfire>
- [4] Instituto Nacional de Pesquisas Espaciais (INPE), “Conjunto de dados de queimadas de terrasbrasilis,” 2023, dados abertos sobre queimadas en Brasil proporcionados por INPE. [Online]. Available: <http://terrasbrasilis.dpi.inpe.br/queimadas/portal/dados-abertos/>
- [5] —, “Conjunto de dados de queimadas de terrasbrasilis, focos de queimadas,” 2023. [Online]. Available: <https://dataserver-coids.inpe.br/queimadas/queimadas/focos/csv/diario/Brasil/>